INFORME DE TRABAJO – MACHINE LEARNING NO SUPERVISADO

Carlos Eduardo Riaño Rodriguez

Bryan Felipe Roa Alvarado

Docente: Ing. Wilson Rojas Reales, PhD(c)

Universidad de Cundinamarca

Introducción a Machine learning

Cundinamarca

Octubre 2026

Tabla de contenido

1. RESPUESTAS AL EJERCICIO DE K-MEANS 4

1. ¿Por qué este ejercicio corresponde a aprendizaje no supervisado? 4

2. ¿Cuál es la diferencia entre clasificación y clustering? 4

3. ¿Qué representa un cluster en este caso? 4

4. ¿Por qué el precio de arriendo puede influir mucho en el resultado? 5

5. ¿Cuántos clusters se definieron? 5

6. ¿Qué características tiene cada cluster? 5

7. ¿Qué estrategia comercial se podría aplicar para cada grupo? 6

8. ¿Cómo podría usar esta segmentación una inmobiliaria? 6

9. ¿Qué pasaría si utilizamos n_clusters=2? 6

10. ¿Qué pasaría si utilizamos n_clusters=4? 7

11. Explique cómo KMeans puede ayudar a una inmobiliaria a mejorar las recomendaciones para los clientes. 7

Tabla resumen de perfiles por clúster 7

2. RESPUESTAS AL EJERCICIO DE PCA 8

1. ¿Cuántas dimensiones tenía el conjunto de datos antes del preprocesamiento y cuántas tiene después de aplicar PCA? 8

2. ¿Qué porcentaje de la varianza explican los dos primeros componentes? 8

3. ¿Qué información puede perderse al representar los datos mediante dos componentes? 8

4. ¿Los grupos identificados por K-Means se distinguen visualmente en el plano PC1-PC2? 8

5. ¿Qué diferencias comerciales existen entre los segmentos encontrados? 9

6. ¿Cambian los grupos al aplicar K-Means sobre los componentes principales en lugar de las variables preprocesadas? 9

7. ¿Qué enfoque recomendaría para la inmobiliaria y por qué? 9

Tabla de varianza explicada por componente 10

3. ANÁLISIS DE RESULTADOS 10

3.1 Análisis del preprocesamiento y calidad de los datos 10

3.2 Análisis de los clústeres con K-Means 10

3.3 Análisis de la distribución geográfica 11

3.4 Análisis de la reducción de dimensionalidad con PCA 11

3.5 Análisis de la visualización PC1-PC2 12

3.6 Limitaciones del análisis 12

3.7 Implicaciones para la inmobiliaria 13

4. CONCLUSIÓN 13

Link de GitHub 14

5. REFERENCIAS 15

1. RESPUESTAS AL EJERCICIO DE K-MEANS

1. ¿Por qué este ejercicio corresponde a aprendizaje no supervisado?

Porque el conjunto de datos no cuenta con una etiqueta o variable objetivo predefinida que indique a qué segmento pertenece cada inmueble, el algoritmo K-Means descubre patrones y agrupa los datos basándose únicamente en la similitud de sus características físicas y económicas, sin intervención humana previa.

2. ¿Cuál es la diferencia entre clasificación y clustering?

Clasificación (Supervisada): Se utilizan datos que ya están etiquetados para que el modelo aprenda a identificar las características de cada clase, así cuando recibe nuevos datos, puede predecir a qué categoría pertenecen.

Clustering (No Supervisado): En este caso, los datos no tienen etiquetas previas, el algoritmo analiza la información y agrupa los registros que tienen características similares, encontrando patrones por sí mismo.

3. ¿Qué representa un cluster en este caso?

Representa un segmento del mercado inmobiliario formado por propiedades con características similares, como el precio, el área, la cantidad de habitaciones y baños, el estrato, la antigüedad y la ubicación. Estas similitudes permiten agrupar viviendas que comparten un perfil parecido dentro del mercado.

4. ¿Por qué el precio de arriendo puede influir mucho en el resultado?

El precio tiene valores mucho más altos, ya que se expresa en millones de pesos, a diferencia de otras variables, como el número de habitaciones o baños, por eso, es importante aplicar un escalamiento, como el StandardScaler, para evitar que el precio tenga demasiado peso al calcular las distancias entre propiedades, igual sigue siendo una variable importante, porque suele estar relacionada con el área y el estrato, lo que ayuda a diferenciar las viviendas más económicas de las de mayor valor.

5. ¿Cuántos clusters se definieron?

En el código se probaron modelos con 2, 3 y 4 clusters para comparar los resultados, en el análisis inicial y la gráfica PCA se trabajó con 3 grupos. Sin embargo, después de revisar los resultados, se considera más conveniente utilizar 2 clusters principales, ya que permiten diferenciar de forma más clara las propiedades según sus características y valor en el mercado.

6. ¿Qué características tiene cada cluster?

Con el modelo de 3 clusters, se identificaron los siguientes grupos de viviendas:

Clúster 0 (Económico/intermedio): Viviendas de aproximadamente 61 m², con 2 habitaciones, 1 baño, estrato 3 y un precio cercano a $2.000.000.

Clúster 1 (Premium): Propiedades más amplias, de unos 154 m², con 4 habitaciones, entre 1 y 2 baños, estrato cercano a 6 y un precio aproximado de $6.300.000.

Clúster 2 (Económico): Viviendas de alrededor de 60 m², con 2 habitaciones, 2 baños, estrato 3 y un precio aproximado de $1.960.000.

Análisis: Los clústeres 0 y 2 presentan características muy similares en cuanto al área, el precio y el estrato. La principal diferencia está en el número de baños. Por otro lado, el clúster 1 reúne viviendas de mayor tamaño, mejor estrato y precio más elevado, por lo que representa el segmento premium del mercado inmobiliario.

7. ¿Qué estrategia comercial se podría aplicar para cada grupo?

- Grupo Económico (Clústeres 0 y 2): La publicidad se puede enfocar en redes sociales, destacando los precios accesibles, la relación calidad-precio, la cercanía al transporte público y las promociones para atraer compradores o arrendatarios.

- Grupo Premium (Clúster 1): Se puede utilizar una estrategia más exclusiva, con fotografías profesionales, atención personalizada y visitas guiadas, resaltando la amplitud de los inmuebles, su ubicación y sus características.

8. ¿Cómo podría usar esta segmentación una inmobiliaria?

Una inmobiliaria podría organizar mejor sus propiedades, crear campañas publicitarias para cada tipo de cliente y establecer precios competitivos según las características de los inmuebles. También podría asignar asesores según el segmento, por ejemplo, asesores especializados en propiedades premium y otros enfocados en viviendas más económicas.

9. ¿Qué pasaría si utilizamos n_clusters=2?

Al utilizar dos clusters, el algoritmo divide las propiedades en dos grupos principales: uno económico o estándar, con viviendas de aproximadamente 61 m² y un precio de $1.980.000, y otro premium, con propiedades de unos 154 m² y un precio cercano a $6.300.000.

Esta opción permite distinguir de manera sencilla las viviendas más económicas de las de mayor valor, lo que facilita el análisis del mercado y la creación de estrategias comerciales.

10. ¿Qué pasaría si utilizamos n_clusters=4?

Al utilizar cuatro clusters, el algoritmo divide las propiedades en grupos más específicos, teniendo en cuenta diferencias como la cantidad de baños, por ejemplo, puede separar las viviendas económicas según tengan uno o dos baños, y hacer lo mismo con las propiedades premium.

Aunque esto permite un análisis más detallado, también puede generar grupos demasiado específicos para una estrategia comercial general, por eso utilizar dos o tres clusters podría ser más práctico, dependiendo del objetivo del análisis.

11. Explique cómo KMeans puede ayudar a una inmobiliaria a mejorar las recomendaciones para los clientes.

KMeans permite agrupar propiedades con características similares para ofrecer recomendaciones más acordes con las necesidades de cada cliente, por ejemplo si una persona busca una vivienda amplia, de estrato alto y con un presupuesto elevado, se le pueden recomendar inmuebles del segmento premium, de esta manera la inmobiliaria puede ofrecer opciones más relevantes, ahorrar tiempo en la búsqueda y mejorar la experiencia del cliente.

Tabla resumen de perfiles por clúster

Clúster	Área (m^2)	Habitaciones	Baños	Antigüedad	Estrato	Precio ($)
Clúster 0	61.3	1.8	1.0	8.6	3.0	2.000.101
Clúster 1	154.6	4.0	1.5	8.4	5.5	6.300.712
Clúster 2	60.7	1.8	2.0	8.5	3.0	1.967.061

2. RESPUESTAS AL EJERCICIO DE PCA

1. ¿Cuántas dimensiones tenía el conjunto de datos antes del preprocesamiento y cuántas tiene después de aplicar PCA?

• Antes (después del preprocesamiento y One-Hot Encoding): 8 dimensiones (6 variables numéricas + 2 variables dummy generadas por las 3 localidades).

• Después de PCA: 2 dimensiones (Componente Principal 1 y Componente Principal 2).

2. ¿Qué porcentaje de la varianza explican los dos primeros componentes?

El Componente 1 explica el 45.10% y el Componente 2 explica el 17.75%. En conjunto, los dos primeros componentes explican el 62.86% de la varianza total de los datos.

3. ¿Qué información puede perderse al representar los datos mediante dos componentes?

Se pierde el 37.14% restante de la información. Esto incluye detalles finos sobre las localidades específicas (Chapinero, Suba, Usaquén), la antigüedad exacta de los inmuebles y la diferencia exacta en el número de baños. Al reducir a 2D, los datos se simplifican, lo que puede hacer que inmuebles ligeramente distintos parezcan iguales.

4. ¿Los grupos identificados por K-Means se distinguen visualmente en el plano PC1-PC2?

Sí. En la gráfica generada, el Clúster 1 (Premium) se separa claramente hacia la derecha (valores positivos del PC1). Sin embargo, los Clústeres 0 y 2 (Económicos) aparecen superpuestos y mezclados en la parte izquierda de la gráfica, ya que son muy similares entre sí y la variación por cantidad de baños queda oculta en la reducción de dimensionalidad.

5. ¿Qué diferencias comerciales existen entre los segmentos encontrados?

La principal diferencia es el poder adquisitivo y el tamaño del hogar. El Clúster 1 representa familias o personas de altos ingresos que buscan amplitud y exclusividad. Los Clústeres 0 y 2 representan personas solas, parejas o familias pequeñas con presupuestos ajustados que buscan eficiencia y ubicación.

6. ¿Cambian los grupos al aplicar K-Means sobre los componentes principales en lugar de las variables preprocesadas?

Sí, pueden cambiar ligeramente. Al aplicar K-Means sobre las 8 dimensiones originales (preprocesadas), el algoritmo tiene en cuenta toda la información, incluyendo la diferencia sutil de los baños (que es lo que separa al clúster 0 del 2). Si se aplica K-Means solo sobre los 2 componentes de PCA, esa información se pierde, y es probable que los clústeres 0 y 2 se fusionen en un solo grupo, quedando solo 2 grupos bien definidos.

7. ¿Qué enfoque recomendaría para la inmobiliaria y por qué?

Recomiendo un enfoque híbrido:

1. Para la segmentación (K-Means): Utilizar los datos preprocesados completos (8 dimensiones) o, preferiblemente, definir n_clusters=2 para evitar agrupar por variables poco comerciales como los baños.
2. Para la visualización y toma de decisiones (PCA): Utilizar PCA con 2 componentes para mostrar a los directivos de la inmobiliaria un mapa visual claro de cómo se distribuye su portafolio, demostrando que la mayoría de sus propiedades son estándar/económicas y un grupo selecto es premium.

Tabla de varianza explicada por componente

Componente	Varianza explicada	Varianza acumulada
PC1	45.10%	45.10%
PC2	17.75%	62.86%

3. ANÁLISIS DE RESULTADOS

3.1 Análisis del preprocesamiento y calidad de los datos

El dataset original contenía variables con formatos inconsistentes (por ejemplo, el precio de arriendo almacenado como texto con separadores de miles). Fue necesario aplicar una limpieza robusta que incluyó la normalización de nombres de columnas, la conversión de variables numéricas y la eliminación de columnas duplicadas (como Estrato.1). Posteriormente, se aplicó StandardScaler a las variables numéricas para que todas contribuyeran de forma equitativa al cálculo de distancias euclidianas, evitando que el precio de arriendo dominara el proceso por su mayor magnitud. Sin este escalamiento, los clústeres habrían estado definidos casi exclusivamente por el precio, perdiendo información relevante como el área o el estrato.

3.2 Análisis de los clústeres con K-Means

Al ejecutar K-Means con k=2, el algoritmo dividió el portafolio en dos grupos con una separación comercial clara y natural: un segmento económico/estándar (área ≈61 m², 1.8 habitaciones, estrato 3, precio ≈$1.98M) y un segmento premium (área ≈154.6 m², 4 habitaciones, estrato 5.5, precio ≈$6.3M). Esta división responde al comportamiento bimodal del mercado inmobiliario en las localidades analizadas.

Al aumentar a k=3, el algoritmo fragmentó el grupo económico en dos subgrupos casi idénticos

(Clúster 0 y Clúster 2), cuya única diferencia apreciable es la cantidad de baños (1 vs 2). Esta división no aporta valor comercial porque ambos subgrupos tienen el mismo poder adquisitivo, área y estrato. Al probar k=4, la fragmentación se intensificó aún más, separando también el grupo premium por número de baños. En consecuencia, se concluye que el número óptimo de clústeres para la toma de decisiones estratégicas es 2, ya que los subgrupos adicionales no representan segmentos comerciales diferenciados.

3.3 Análisis de la distribución geográfica

La distribución por localidad dentro de cada clúster resultó relativamente homogénea (aproximadamente 33% por localidad en cada grupo). Esto indica que la localidad (Chapinero, Suba, Usaquén) no es la variable que determina el segmento al que pertenece un inmueble. En otras palabras, en las tres localidades convive una oferta económica y una premium de manera equilibrada, lo cual es coherente con la estructura urbana de Bogotá: cada localidad presenta zonas residenciales de distintos estratos. Por lo tanto, la estrategia comercial debe enfocarse en las características físicas (área, habitaciones, estrato) más que en la ubicación como criterio de segmentación.

3.4 Análisis de la reducción de dimensionalidad con PCA

El PCA sobre los 8 componentes (6 numéricos + 2 dummy por localidad) mostró que el primer componente explica el 45.10% de la varianza y el segundo el 17.75%, acumulando un 62.86%. El PC1 está claramente dominado por las variables de tamaño y precio (área, habitaciones, estrato, precio), por lo que se puede interpretar como un "eje de capacidad adquisitiva y tamaño del inmueble". El PC2, con menor peso, probablemente captura la variabilidad residual asociada a la localidad y la antigüedad. Que el PC1 por sí solo explique casi

la mitad de la información indica que existe una correlación fuerte entre precio, área y estrato: a mayor área, mayor estrato y mayor precio. Esta estructura colineal es la razón por la cual los grupos económicos y premium se separan tan claramente en la gráfica PC1-PC2.

3.5 Análisis de la visualización PC1-PC2

La proyección en dos dimensiones confirma visualmente la estructura encontrada con K-Means: el Clúster premium se separa hacia la derecha (valores positivos de PC1), mientras que los clústeres económicos se agrupan al lado izquierdo. Sin embargo, los Clústeres 0 y 2 se superponen casi por completo, lo cual valida la conclusión de que su separación es artificial y no aporta información estratégica. En otras palabras, la gráfica PCA actúa como un validador visual del número óptimo de clústeres: si dos grupos se ven indistinguibles en el plano, no tiene sentido tratarlos como segmentos comerciales separados.

3.6 Limitaciones del análisis

El análisis presenta tres limitaciones principales que se deben considerar antes de implementar una estrategia comercial:

• Pérdida de información en PCA: Al reducir a 2 dimensiones se pierde el 37.14% de la varianza, lo cual oculta detalles importantes como la antigüedad exacta o la localidad específica. Por esta razón, PCA se utiliza solo para visualización y no para la asignación final de clústeres.

• Variables faltantes relevantes: El modelo no incluye variables que podrían enriquecer la segmentación, como amenidades (parqueadero, balcón, gimnasio), cercanía a transporte o estado de conservación del inmueble.

• Dependencia de la escala: Aunque se aplicó StandardScaler, el precio sigue siendo una variable

con alta influencia por su correlación con otras variables. Un análisis de sensibilidad (probar con y sin precio) podría arrojar resultados distintos.

3.7 Implicaciones para la inmobiliaria

Los resultados permiten concluir que:

1. El portafolio es naturalmente bimodal. La inmobiliaria puede gestionar su inventario con dos estrategias comerciales diferenciadas en lugar de intentar segmentar en cuatro o más grupos.
2. La localidad no discrimina segmentos. La empresa no debería diseñar campañas por localidad, sino por características del inmueble.
3. El clúster premium concentra el mayor valor económico. Aunque probablemente representa una fracción menor del inventario (a confirmar con el conteo exacto por clúster), su precio triplica al del segmento económico, por lo que merece una estrategia de marketing especializada.
4. PCA valida la estrategia de dos segmentos. La proyección 2D confirma que el precio y el área son las variables que más separan a los inmuebles, lo que respalda la decisión de comercializar con dos perfiles claros.

4. CONCLUSIÓN

Tras aplicar técnicas de aprendizaje no supervisado, se concluye que el portafolio de la inmobiliaria presenta una estructura natural de dos grandes segmentos comerciales: un grupo de inmuebles económicos/estándar (alrededor de $2.000.000 de arriendo, 60 m² y estrato 3) y un grupo premium (alrededor de $6.300.000, 154 m² y estrato 5.5).

Aunque K-Means con n_clusters=3 o 4 logra encontrar subgrupos, estos se basan en diferencias mínimas como la cantidad de baños, lo cual no representa una estrategia comercial diferenciada. Por lo tanto, se recomienda utilizar n_clusters=2 para la toma de decisiones estratégicas y usar PCA (2 componentes) exclusivamente como herramienta de visualización para comprender que el 62.86% de la variabilidad del mercado inmobiliario está explicada por el tamaño y el precio del inmueble.

Link de GitHub

https://github.com/carlosedu1234/R1-A3-S12-INFORME-DE-TRABAJO-ML-NO-SUPERVISADO.git

5. REFERENCIAS

Clustering: K-means and hierarchical. (s.f.). *Video*. YouTube.

PCA: Principal component analysis. (2019). *Video*. YouTube.

Singular value decomposition (SVD) and image compression. (2021). *Video*. YouTube.

RLlib. (2026). *RLlib: Industry-grade, scalable reinforcement learning*. https://docs.ray.io/en/latest/rllib/index.html

Quiroz-Chavil, H. K., Capuñay-Uceda, C. E., Collantes Santisteban, L. J., Collantes Santisteban, S., Collantes Santisteban, C. A., & Collantes Alvarado, K. S. Fundamentos matemáticos para machine learning.

Rojas, E. M. (2020). Machine Learning: análisis de lenguajes de programación y herramientas para desarrollo. *Revista Ibérica de Sistemas e Tecnologias de Informação*, (E28), 586-599.

Moreno-Pallares, M. G., Moreno-Pallares, R. R., & Mejia-Peñafiel, E. F. (2022). Entrenamiento de Redes Neuronales Artificiales con Aprendizaje No Supervisado en el control de calidad del análisis. *Polo del Conocimiento*, *7*(5), 1584-1593.

Herrera Eras, J. F. (2026). *La Matemática detrás del aprendizaje de máquinas: Fundamentos y aplicaciones: regresión y Análisis de Componentes Principales (PCA)* (Bachelor's thesis, Quito: EPN, 2026.).